



北京航空航天大学
B E I H A N G U N I V E R S I T Y

第三十五届“冯如杯”竞赛主赛道项目论文
基于路面缺陷识别与预测的无人机载道路维护
一体化系统

2025 年 4 月

摘要

针对传统公路人工巡检中存在的效率低下、安全风险大且缺陷评估依赖人为判断等问题，我们团队研发了一套基于无人机技术平台的智能公路维护系统。

目前，在这一领域的研究普遍存在三大难题：一是多传感器采集的数据难以高效融合处理；二是巡检路径规划与缺陷检测之间缺乏实时的联动机制；三是路面退化老化预测模型无法有效兼顾铺装路面和非铺装路面的不同特性。针对这些问题我们团队通过硬件设备与算法设计的协同优化，实现了技术突破，为公路养护提供了一个智能化的解决方案。

本系统采用 Crazyflie 2.1 微型无人机搭载 AI Deck 边缘计算模块与 Multiranger 多向测距传感器，构建“端-边”协同检测平台，实现高清图像采集与优化后的 ResNet-18 模型的实时缺陷识别。通过改进后的路径规划算法使无人机自主飞行与毫米级深度数据同步采集，实现“起降-巡检-返航”零人工干预的全自主闭环作业。最后基于多约束区域生长算法，融合深度梯度与纹理特征，使用不同材质路面磨损深度的双模态预测模型，处理采集到的数据，实现对公路磨损的智能预防与维护。

本项目成果首次实现“图像采集、缺陷定位、深度检测、磨损预测、维护决策”全流程自动化闭环，填补了动态环境自适应检测、多源数据融合预测等关键技术空白，为公路设施智能化运维提供了可工程化落地的解决方案。

关键词：道路维护，深度学习，图像识别，路径规划，磨损预测

Abstract

For the problems of low efficiency, high safety risks, and defect assessment relying on human judgment in traditional highway manual inspection, our team has developed an intelligent highway maintenance system based on the unmanned aerial vehicle technology platform.

Currently, there are generally three major difficulties in research in this field: First, it is difficult to efficiently fuse and process the data collected by multiple sensors; second, there is a lack of a real-time linkage mechanism between inspection path planning and defect detection; third, pavement degradation and aging prediction models cannot effectively take into account the different characteristics of paved and unpaved roads. In response to these problems, our team has achieved technological breakthroughs through collaborative optimization of hardware equipment and algorithm design, providing an intelligent solution for highway maintenance.

This system uses the Crazyflie 2.1 micro unmanned aerial vehicle equipped with the AI Deck edge computing module and the Multiranger multi-directional ranging sensor to build an end-edge collaborative detection platform, realizing high-definition image acquisition and real-time defect identification of the optimized ResNet-18 model. Through the improved path planning algorithm, the unmanned aerial vehicle can fly autonomously and synchronously collect millimeter-level depth data, realizing a fully autonomous closed-loop operation of takeoff-landing-inspection-return without any human intervention. Finally, based on the multi-constraint region growing algorithm, fusing depth gradient and texture features, a bimodal prediction model for pavement wear depth of different materials is used to process the collected data to achieve intelligent prevention and maintenance of highway wear.

The results of this project have realized the fully automated closed-loop of the entire process of image acquisition, defect location, depth detection, wear prediction, and maintenance decision-making for the first time, filling the gaps in key technologies such as dynamic environment adaptive detection and multi-source data fusion prediction, and providing an engineering-ready solution for intelligent operation and maintenance of highway facilities.

Keywords: road maintenance, deep learning, image recognition, path planning, wear prediction

目录

一、 绪论	1
(一) 研究背景.....	1
(二) 国内外研究现状	2
(三) 关键问题.....	3
二、 研究内容	3
(一) 路面缺陷图像识别模型.....	3
1. 图像分类模型选择	3
2. 数据集的搜索与分类.....	4
(二) 无人机路径规划算法	4
1. 经典 A* 算法理论基础	4
2. 自适应采样增强的技术改进	4
(三) 动态掩码区域生长算法.....	5
(四) 磨损深度预测模型.....	5
1. 公路磨损程度变化率随时间变化的函数推导.....	5
2. 公路磨损程度的计算.....	7
(五) Crazyflie 无人机操控技术原理.....	8
1. 用户通信	8
2. 定位原理	9
3. 飞行控制	10
三、 系统设计与搭建	11
(一) 系统硬件架构.....	11
1. 无人机平台.....	11

2. 定位系统	11
3. 地面站.	12
4. 硬件架构特点	12
(二) 软件算法实现.	12
1. ResNet-18 模型训练与缺陷识别算法	12
2. 基于改进 A* 算法的避障路径生成算法与自适应采样策略	13
3. 基于多约束生长的磨损深度区域分割算法	13
4. 深度预测函数与蒙特卡洛算法.	13
5. 软件数据流程	13
四、 系统功能验证	13
(一) 路面缺陷精确检测.	13
(二) 区域磨损深度重构.	14
(三) 区域生长深度划分与统计	15
(四) 精准磨损深度预测.	16
五、 项目优势	16
(一) 算法优势.	16
1. 路面缺陷精确识别	16
2. 改进 A* 算法高效路径规划	17
(二) 模型优势.	17
1. 多模态预测架构.	17
2. 动态鲁棒性增强.	17
(三) 系统优势.	17
1. 全链条自动化	17

2. 工程可扩展性 17

六、 应用前景 17

 (一) 商业价值. 17

 (二) 产品优势. 18

 (三) 未来展望. 18

结论. 19

参考文献. 20

一、绪论

（一）研究背景

加快建设交通强国，是以习近平同志为核心的党中央立足我国发展阶段性特征、着眼国家战略全局、面向未来竞争格局作出的一项重大战略决策。党的十九届五中全会进一步强调，要加快建设交通强国，构建现代化高质量国家综合立体交通网，以保障支撑现代化经济体系和社会主义现代化强国建设。公路交通作为综合交通体系中的重要组成部分，逐步实现公路维护治理体系和治理能力现代化，使管理手段由传统向数字转型是未来的发展趋势。

我国拥有全世界规模最大的公路网，截至 2022 年底，公路总里程已突破 535 万公里。这么庞大的公路网，给公路养护工作带来了巨大的挑战。

根据交通运输部的统计数据显示，我国二级及以上公路，平均每公里每年的养护成本在 10 万元到 25 万元之间，成本高昂。并且在公路巡检方面，传统的巡检模式暴露出了不少问题，主要存在以下三方面的矛盾：

效率与精度失衡的矛盾：人工巡检平均速度为 0.5km/h（而无人机可达 8km/h）耗时又耗力，难以实现大范围快速检测分析及处理，尤其在交通量大的路段，无法实时监控突发的损坏状况。据统计在公路养护巡检过程中裂缝检出率往往不足 70%（《中国公路养护技术规范》2021 版），而不同巡检员对路面裂缝、坑槽等问题的严重程度评估标准不一，且肉眼容易漏检有潜在的风险。不仅如此，传统方法的自动化程度低，依赖卷尺、相机等简单设备，难以快速排查出存在的问题消除安全隐患。

安全与成本冲突的矛盾：从相关统计来看，在公路养护作业过程中，大约 60% 到 70% 的事故都发生在那些高危路段，像山区的急弯、又长又陡的坡道、靠近悬崖和河流的路段，还有隧道和桥梁这些地方。根据有关学术研究估算，每年在这些高危路段进行养护作业时，平均会发生 30 到 50 起致人死亡的事故，这样的损失我们实在难以承受。

另一方面，要是采用桥梁检测车这类大型专业设备，一天的租赁或使用成本就超过 5000 元人民币。这么高的费用，让一些经济欠发达地区或者农村地区根本难以承受，也就没办法大范围地使用这些设备来进行公路养护工作。

检测与预测割裂的矛盾：现有系统仅能实现缺陷定位，如只发现哪里路面有轻微损毁情况，而没有退化机理建模能力，往往因为没有结合重载车辆激增而导致该路段加速结构性损坏的预测，使得预防性养护实施率较低事故频发。

国际道路联合会（IRF）提出“Smart Maintenance 4.0”战略是道路养护领域面向未来数字化转型的重要框架，其核心目标是通过新兴技术（如 AIoT、大数据、数字孪生等）提升道路基础设施的维护效率、可持续性和智能化水平。重点强调了 AIoT 技术在养护领域的深度整合。无人机搭载的计算设备可构建毫米级检测能力（Z 精度达 $\pm 0.1\text{mm}$ ）实现实时数据采集，构建关联数据库，可预测裂缝扩展速度和未来有无塌陷风险。

但即便如此现有研究仍存在三大技术断层：即感知层的多传感器数据融合效率低下，决策层的路径规划与缺陷识别的动态耦合不足，预测层的缺乏材料特性与交通荷载

的耦合建模数据。

我们团队研发的这套基于无人机技术平台的智能公路维护系统，通过“从实时感知到路径规划再到精准预测”的技术闭环，实现了对公路健康状态的自主评估与寿命周期的管理。

（二）国内外研究现状

在《公路桥梁维护管理中的智能监测技术应用分析》这篇学术文章中，作者将传感器技术、数据传输、远程控制与预警系统整合为“监测-分析-决策”闭环体系，突破了传统单一技术应用模式，形成全链条化管理。但它缺少了应对技术快速迭代所需要的 5G 通信及 AI 算法的升级，有技术过时的风险^[1]。

而《高速公路智能巡检养护管理系统的开发与应用》创新地引入 AI 预测模型和优化算法，推动养护从“被动响应”转向“主动预防”，减少突发维护需求。对比传统依赖人工经验的维护模式，更具科学性与前瞻性。但它缺少了对成本与经济效益的分析，未提及系统部署的初期投资（如传感器、服务器采购）及长期运维成本，这会影响到实际推广的可行性^[2]。

《Automated decision making in highway pavement preventive maintenance based on deep learning》中“以 100 米的间隔，交通负荷数据，气候历史记录和所选高速公路维护记录的十年遇险测量数据被视为 ANN 模型的输入数据”，创新地整合交通、气候、维护记录等多维度数据，并设计质量控制流程，弥补传统研究仅依赖单一数据的不足。不足之处在于它仅针对特定路段验证模型，未讨论不同气候、交通负荷或材料特性下模型的泛化能力，可能限制其普适性^[3]。

《Intelligent Road Inspection with Advanced Machine Learning; Hybrid Prediction Models for Smart Mobility and Transportation Maintenance Systems》的作者根据伊朗德黑兰-库姆高速公路的 236 个路段，结合 PCI 人工计算与 FWD 测试数据（7 个传感器记录弯沉值），“The proposed method enhances the safety of the PCI determination process by eliminating the field inspection of the pavement.”，将 FWD 结构测试数据直接用于 PCI 预测，替代危险且低效的人工巡检，突破传统 PCI 计算依赖视觉或单一数据源的局限。对比业界现状，现有研究多关注图像或粗糙度指标，鲜少整合结构性能数据。其不足之处在于缺乏普遍适用性，它仅基于伊朗单一高速公路数据，未验证模型在不同气候、交通负荷或路面材料下的普适性，会限制其在其他地区的推广及应用^[4]。

而《Automated Road Damage Detection Using UAV Images and Deep Learning Techniques》这篇学术文章中，作者创新地结合几个国家的图像数据，以增强模型对不同道路环境和损坏类型的适应性，弥补单一数据集导致的过拟合问题。但是它的数据集多样性与代表性不足，西班牙数据集仅包含 327 个裂缝（D00）样本，且未涵盖所有损坏类型（如 D10、D20），可能导致模型对特定类别检测能力弱，会影响最终的检测结果^[5]。

表 1 不同版本 ResNet 模型间的比较

版本	ResNet-18	ResNet-34	ResNet-50	ResNet-101
层数	18	34	50	101
卷积层	16	32	48	96
参数量	较少	较多	中等	较多
性能	一般	较好	很好	很好
用途	快速部署	平衡性能	高性能	高性能
特点	简单快速	平衡速度与精度	使用瓶颈层提高性能	使用深层网络提高性能

（三）关键问题

利用无人机代替人工巡检，打破检测效率瓶颈，满足路面维护检测需求。通过深度学习对道路表面图像进行缺陷识别，量化评估标准，减少缺陷识别的主观性，避免依赖人工经验判断导致的失误。根据识别到的道路表面缺陷位置，动态规划无人机采样路径，减少冗余飞行。考虑环境因素的变化对材料磨损的影响，解决传统单指数衰减模型对道路表面退化规律适配性差的问题。

二、研究内容

（一）路面缺陷图像识别模型

1. 图像分类模型选择

ResNet 是一种深度残差网络，通过引入残差连接 (Residual Connections) 来解决传统深度网络中随着层数增多训练难度急剧增加的问题。在 torchvision 库中有已经经过预训练的各类 ResNet 模型，本项目在此基础上，继续进行迁移学习，来适配本项目的分类要求。目前有 ResNet18、ResNet34、ResNet50、ResNet101 等多个版本。其中 ResNet-18 和 ResNet-34 是 ResNet 系列中最浅的两个版本，分别包含 18 层和 34 层（卷积层 + 全连接层）。其特点是计算效率较高，适合于低资源环境，适用于较小规模的图像分类任务。在资源受限或实时性要求较高的场景中效果更为显著。ResNet-50、ResNet-101 是 ResNet 的深层版本，其优点是更深的网络可以提取更加丰富的特征。

Resnet-18 相对于其它模型而言首先是具有轻量化的特点：由于它的参数量少（仅含 1160 万参数）所以特别适合应用在无人机计算单元、车载 GPU 等小型设备上。。由于它的单张图像推理耗时约 5-10ms (NVIDIA Jetson Nano)，所以可以满足实时检测需求 (≥ 30 FPS)；其次这个模型还具有残差结构优化特征提取的功能：模型可以通过跳跃连接 (Shortcut) 有效缓解梯度消失问题，大大地提高了对细微缺陷（如地面裂缝宽度深度、坑洼深度范围）的敏感性，不仅如此还通过不同卷积层，可以捕捉到从局部纹理 (3*3 卷积) 到全局结构 (池化层) 的多尺度缺陷特征，使检查更全面。除此之外，此模型可以通过数据增强（随机亮度调整/对比度调整）提升模型在阴影、逆光条件下的识别稳定性，而且对路面污渍、水渍等非缺陷干扰的误报率 $< 5\%$ ，具有很强的抗干扰能力。

通过实际测试，使用 ResNet18 进行迁移学习并用于单目标分类时，效果最佳，准

确度可达 90% 以上。在使用 ResNet50 进行特征提取时，准确度最高，在判断并剔除相同或极相似图片时，表现最佳。

2. 数据集的搜索与分类

本项目采用 Kaggle 数据集进行图集训练。Kaggle 上的数据集大多为小至中型数据集，大小从 5MB 到 10GB 不等。与 ImageNet 相比，Kaggle 上的数据集通常规模较小，但数据集质量和应用场景通常更加具体和聚焦。而且，Kaggle 上的数据集针对性强，其上的许多数据集都是针对某一特定问题设计的，适合解决实际问题。

尽管 Kaggle 上的数据集的质量不一，标注的准确性也因任务而异。但是数据集的种类多样，这方便我们选择符合自己研究目标的数据集，从而进行精细化的训练。因此，本项目训练模型所用的图像集大多数来源于 Kaggle 网站。

我们在分类任务中，保证了每个类别的样本数量相对均衡，避免类别不平衡导致模型性能下降。我们还确保数据集中包含足够多样的样本，以提高模型的泛化能力和鲁棒性。

（二）无人机路径规划算法

1. 经典 A* 算法理论基础

A* 算法作为启发式搜索算法的代表，其核心在于构建代价评估函数：

$$f(n) = g(n) + h(n) \quad (1)$$

其中：

- $g(n)$ ：从起始节点到当前节点 n 的实际路径代价
- $h(n)$ ：当前节点 n 到目标节点的启发式估计代价
- $f(n)$ ：节点的综合优先级评估值

传统实现采用八邻域搜索策略，定义移动代价为：

$$g(n_{i,j}) = \begin{cases} \sqrt{2}, & \text{斜向移动} \\ 1, & \text{横向/纵向移动} \end{cases} \quad (2)$$

启发函数 $h(n)$ 常选用曼哈顿距离或欧氏距离。这里我们使用欧氏距离：

$$h(n) = \sqrt{(x_{goal} - x_n)^2 + (y_{goal} - y_n)^2} \quad (3)$$

2. 自适应采样增强的技术改进

为提高关键区域采样分辨率，本项目在路径规划阶段注入智能检测策略。

- 密集采样：对禁飞区按面积 10% 密度添加随机检测点
- 动态调整：根据威胁权重 w_i 实时调整航点间距 Δd

$$\Delta d = \begin{cases} 0.5m, & w_i > 2.5 \\ 1.0m, & \text{otherwise} \end{cases} \quad (4)$$

该策略使较均匀采样方案数据有效性得到显著提升。

（三）动态掩码区域生长算法

我们采用区域生长算法通过迭代合并相似像素实现目标区域分割。在分类任务中，我们保证每个类别的样本数量相对均衡，避免类别不平衡导致模型性能下降。我们还确保数据集中包含足够多样的样本，以提高模型的泛化能力和鲁棒性。

（四）磨损深度预测模型

1. 公路磨损程度变化率随时间变化的函数推导

针对公路的磨损问题，首先我们分析某一时刻，人和车辆对路面的作用力，以及使路面产生形变磨损的瞬时效果。根据 Archard 磨损定律，我们做如下推导^[6]。

$$D(x) = \int_0^l k p^m(x) dl \quad (5)$$

D 是相对滑动距离为 1 时的磨损深度， k 为温度加速系数， p 为接触面产生的压强， m 为压强 p 对磨损率的影响指数。再结合压强 $p=G/S$ ，我们得到路面磨损程度的变化率的表达式如下：

$$\frac{\partial D}{\partial t} = f l k \left(\frac{N}{S} \right)^m \quad (6)$$

由 Arrhenius 方程，我们得到温度加速系数 k 随温度 T 的变化^[7]。如下：

$$k = k_0 e^{-\frac{E_a}{k_B T}} \quad (7)$$

k_0 为低温下的磨损系数 (1)， k_B 为玻尔兹曼常量， T_0 为常温 (取 20 摄氏度)， E_a 为单个材料分子的激活能， Q 为单位接触面积吸收/放出的热量， f 为频率， v 为摩擦时的相对速度， M 为摩擦接触的材料部分质量。接下来通过如下过程求算 T ：

$$M = \rho V \quad (8)$$

$$V = S h \quad (9)$$

$$Q_{in} = cM\Delta T \quad (10)$$

$$T = T_0 + \Delta T \quad (11)$$

同时, 根据调研发现: 不同的磨损频率会影响材料在某段时间内放出的热量, 二者成负相关关系。因此可推导出 (其中 λ 为与材料散热能力有关的系数):

$$Q_{in} = W - Q_{out} = \mu N \left(l - \lambda_Q \frac{v}{f} \right) \quad (12)$$

最终得出:

$$\frac{\partial D}{\partial t} = flk_0 e^{-\frac{E_a}{k_B \left(T_0 + \mu N \frac{l - \lambda_Q \frac{v}{f}}{c\rho S h} \right)}} \left(\frac{N}{S} \right)^m \quad (13)$$

通过上述推导, 我们得到单位时间路面产生的磨损深度与频率的关系。在得到公路某一点处瞬时产生的磨损程度的基础上, 把这一微观瞬时变化进行推广, 使其适用于公路在较长时间段内受到的磨损。

通过生活经验可知, 公路在建造投入使用初期, 一定是为了满足某种使用需求; 但随着时间的推移, 公路的使用频率会有所下降。经过调查, 我们发现, 在没有外界干预 (如其他人类活动的影响) 下, 公路的使用率成指数级的下降趋势。

所以, 我们假设自然条件下的公路使用频率为:

$$f = \alpha e^{-\gamma t} + \beta \quad (14)$$

在得到频率与磨损程度变化率关系的基础上, 我们将其与不同时间人踩公路的频率的关系相结合, 得出最终不同时间内的磨损程度变化率的关系式:

$$D = ae^{-kt} + bt + c \quad (15)$$

根据该关系式, 我们绘制出台阶磨损量 D 与时间的关系曲线, 发现与图 1 的第一阶段相符合^[8]。




图1 磨损程度变化率随时间的变化曲线

由于自然条件下，公路的磨损不会像工业生产中机器零件的磨损那样频繁，所以不会进入图 x 中曲线的第二阶段。

通过以上验证，可以证明我们理论推导的公路磨损程度变化率随时间的变化函数是正确的。

2. 公路磨损程度的计算

蒙特卡洛算法 (Monte Carlo Method) 是一种基于概率统计的数值计算方法，其核心思想是通过大量随机采样逼近复杂问题的解析解^[9]。

在磨损深度预测中，我们通过以下机制实现高精度建模：

- 随机参数搜索：定义模型参数的可行域范围（如材料刚度系数 $K_{base} \in [10^{-6}, 10^{-4}]$, $K_{base} \in [10^{-6}, 10^{-4}]$ 、交通荷载强度 $A \in [500, 1500]$, $A \in [500, 1500]$ ）
在参数空间内生成均匀分布的随机样本（代码中迭代次数默认 $N = 1000$, $N = 1000$ ）
- 损失函数评估：计算每个参数组合的预测误差：

$$MSE = \frac{1}{n} \sum_{i=1}^n (dpred(i) - dobs(i))^2 \quad (16)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (dpred(i) - dobs(i))^2 \quad (17)$$

保留均方误差 (MSE) 最小的参数组合作为最优解

- 全局最优逼近：通过大数定律保证收敛性，当 $N \rightarrow \infty$ 时，算法以概率 1 收敛到全局最优解。实际工程中采用有限次迭代（通常 $N \geq 1000$ ），在计算效率与精度间取得平衡。相比于传统最小二乘法，本方法具有以下优势，如表 2 所示。

使用蒙特卡洛方法，在磨损程度变化率与时间关系的二维图像上找到一个长方形完全覆盖总磨损程度 D 。我们通过预估公路刚建成时磨损频率的最大值，推出公路磨损程度变化率最大值，此最大值即为长方形的宽的初始值。长方形的长即为公路的估计年龄

表 2 传统最小二乘法与蒙特卡洛优化法比较

对比维度	传统最小二乘法	蒙特卡洛优化法
初始值依赖	高度敏感，易陷入局部最优	无初始值要求
计算复杂度	$O(nk^2)$ (n 为数据量)	$O(Nm)$ (N 为迭代次数)
适用场景	低维凸优化问题	高维非凸优化问题
工程可解释性	依赖梯度信息，物理意义模糊	参数范围约束增强物理合理性

(当前年份与预估公路建成年份的差值)。

在此长方形内部，我们随机选取尽可能多的点，如本模型中我们取 $n = 10^9$ ，确定这些点中在曲线下方的点的个数 $count$ ， $count$ 与 n 之比即为变化曲线与时间轴围成面积的估计值 D' 与长方形面积 S 之比，通过 $count$ ， n ， S 三个已知量即可求得总磨损程度。

由于在实际情况中，公路在较长时间段内的磨损不会像工业生产中使用的机器零件磨损那样的频繁。短时间内不会产生太多的热量，使台阶的内部温度发生明显变化。所以我们可以取 T 为常温 $T_0 = 20$ 摄氏度 (293K) 为定值。对式 13 进行简化，得到式 18：

$$\frac{\partial D}{\partial t} = flk_0 e^{-\frac{E_a}{k_B T}} \left(\frac{N}{S} \right)^m \quad (18)$$

该式左右两侧对 t 直接进行积分，得到磨损深度 D - t 关系式。避免了应用蒙特卡洛方法的复杂积分过程，提高了计算效率，后续的预测值与实际测量值的比较与参数调整的方法与过程不变。

简化后的方法避免了简化前使用蒙特卡洛方法计算积分导致的系统误差。经过验证，该方法所得到的频率时间关系解析式与简化前参数的差值在误差允许范围内，证明了简化方法的合理性。

(五) Crazyflie 无人机操控技术原理

1. 用户通信

通过配置客户端并更新 Crazyflie 中的固件，我们在 Crazyflie 客户端中选择正确的地址，实现正确的设备映射，使之成功连接到 Crazyflie 无人机。

连接成功以后，遥测数据不断地从无人机发送到 crazyfile 客户端。当移动并 Crazyflie 无人机的姿态时，便能够看到飞行数据实时更新，以及电池状态和连接质量。




图 2 客户端显示无人机实时姿态

2. 定位原理

Loco Positioning system (LPS) 是一种用于确定特定区域内物体位置的技术或系统，通常覆盖范围较小，如建筑物内部或城市街区。

Crazyflie 无人机基于超宽带 (UWB) 技术，使用的 LPS 定位系统，并支持双向测距 (TWR) 和到达时间差 (TDOA) 两种模式。子系统通过 Decawave 的 DWM1000 模块可以实现高精度的定位。

双向测距 (TWR) 通过无人机 (如 Crazyflie) 与多个基站之间的双向信号交互，直接测量信号收发时间 (Time of Flight, ToF)，从而计算距离。首先无人机向基站发送请求信号，基站回复响应信号，无人机的子系统记录信号往返时间，然后通过时间差计算距离，最后进行定位解算，结合至少 4 个基站的测距数据，通过三边定位或最小二乘法解算标签的三维坐标，确定实时位置。

TWR 的优点是高精度，平均精度可达厘米级，特别适合小范围场景。但是它的缺点是能耗高，因为需要频繁的双向通信，所以消耗的电力较大，对无人机的续航能力会有一定影响。

到达时间差 (TDOA) 模式是基于无人机发射信号到达不同基站的时间差，通过双曲线方程来解算位置。首先整个系统进行时间同步，所有基站需保持严格时钟同步 (如通过有线网络或无线信号)，然后接收信号，无人机发送单次脉冲信号，各基站记录到达时间差，最后通过双曲线方程计算定位，利用时间差生成多组双曲线，其交点即为无人机实时位置。

TDOA 具有低功耗的优点，无人机仅需单次发射信号即可，特别适合大规模终端应

用场景，如图 3 所示。但是 TDOA 的局限性也很明显，就是对时间同步要求较高，如果子系统时钟偏差会显著影响整体的定位精度，可以考虑增加额外的时间同步机制。




图 3 TDOA 定位原理

通过在客户端中配置各锚点的位置，实现了对无人机的有效定位，如图 4 所示。




图 4 配置锚点位置

3. 飞行控制

进一步结合 Python 控制程序开发，利用 `cflib` 库实现飞行控制逻辑：初始化时调用 `cflib.crtp.init_drivers()` 驱动通信模块，通过 `PositionHlCommander` 类构建 PID 控制器，编写同步/异步日志回调函数实时获取飞行数据，最终完成起飞、航向调整、目标点

飞行及降落的全流程自动化控制。实验表明，该系统在复杂空间场景中实现了航迹规划与动态避障的协同控制，定位数据更新频率达 100Hz，验证了开源无人机平台在自主导航研究中的可行性与扩展性。

三、系统设计与搭建

(一) 系统硬件架构

1. 无人机平台

采用 Crazyflie 2.1 微型无人机。机载 AI Deck 模块实现边缘计算,使用 *imagecallback* 实时处理图像。使用 *Multiranger* 多向测距传感器,通过 *Multiranger* 类实现高度/避障检测,通过 *PositionHlCommander* 实现精确定位。

2. 定位系统

基于机载 IMU 与光流传感器融合实现相对定位。通过地面站坐标系定义全局参考系,以起飞点为原点实现绝对定位。



图 5 无人机与定位系统的互联

3. 地面站

运行控制脚本的计算机通过 2.4GHz 无线通信（‘radio://0/80/2M’协议）与无人机进行交互。

4. 硬件架构特点

传感器数据采样率高，实现实时响应。基于 Crazyflie 强大的模块化扩展功能，使得 AI Deck 的 GPIO 接口支持外部传感器即插即用。

（二）软件算法实现

1. ResNet-18 模型训练与缺陷识别算法

我们使用 PyTorch 框架训练一个 ResNet-18 模型，在训练过程中，涉及到了数参数设置、数据预处理与数据增强、损失函数选择，优化器选择、训练和验证过程等方面，下面一一对这些过程进行阐释。

在参数选择时，我们将 batchsize 的值设置为 32，即每个训练批次加载 32 张图片。这有助于减少内存消耗，并提高模型的泛化能力。epoch 通常要设置为一个较大的值以保证模型获得更好的训练结果，但是经过权衡了训练时长和模型效果，我们决定将 epoch 设置为 10，以缩短训练时间并尽量减少对模型的影响。经过实际验证，epoch 在设置为 10 时，模型已经接近收敛，最终也得到了不错的效果。同时，为了提高训练速度，优先选用 GPU 进行训练。

在这一部分，我们采用了多种数据处理和数据增强的手段：通过随机裁剪，裁剪出 224*224 的区域，增加图像多样性，通过随机水平翻转，模拟不同的拍摄角度。通过色彩抖动，在亮度、对比度、饱和度和色相上进行随机调整，增强模型的鲁棒性。通过仿射变换，随机对图像进行旋转和位移，进一步提升数据的多样性。通过归一化处理，训练集和验证集都使用了相同的均值和标准差对图像进行标准化，确保数据输入一致性。经过本小组的实验，证明这些数据增强手段有助于提高模型的泛化能力，减少过拟合。

在模型构建与选择过程中，我们选择 ResNet18 作为模型基础，并在其全连接层添加 Dropout 层，经过实验，该步骤能够有效解决过拟合的问题。

在优化器的选择上，我们采用了简单的 Adam 优化器，其自适应学习率和动量方式能够有效提高收敛速度并避免局部最优解；在损失函数的选择方面，我们使用了加权的 CrossEntropyLoss，确保了在类别不平衡的情况下，不同类别的样本对损失函数的影响相对均衡。

训练过程简述如下：在每个 epoch 中，模型进入训练模式，逐批次地计算损失，并执行反向传播和梯度更新。每 50 个 batch 打印一次训练损失。紧接着，模型进入验证过程，在验证阶段，模型进入评估模式，计算验证数据的平均损失和准确率。

训练结束后，我们将训练好的模型保存为 classification.pth，方便后续加载进行推理或继续训练。

2. 基于改进 A* 算法的避障路径生成算法与自适应采样策略

动态威胁建模: 通过禁飞区面积占比计算威胁权重, 面积越大权重越高, 实时计算每个路径点的威胁成本, 融合欧氏距离与缺陷分布特征, 实现安全与效率的平衡。

自适应采样策略: 对禁飞区按面积 10% 密度添加随机检测点, 数动态调整分辨率: 威胁权重 >2.5 时航点间距自动缩小至 0.5m。最后验证禁飞区深度异常, 确保采样有效性。

3. 基于多约束生长的磨损深度区域分割算法

我们通过判断联合深度有效性与空间掩码 ‘mask’ 过滤无效点, 深度梯度阈值隐含在数据预处理中, 剔除平坦区域。

我们使用设置 1.5 网格单位搜索半径, 控制生长范围。然后计算区域均值/方差, 动态调整生长阈值。我们通过增加判断阻止向禁飞区外生长, 保持缺陷边界的完整性。

我们使用 KDTree 索引, 将邻近搜索复杂度降低, 处理速度大幅提升, 避免重复计算, 优化性能。

4. 深度预测函数与蒙特卡洛算法

我们从结构化报表中提取区域 ID、检测年份及平均深度数据, 构建时间序列并转换为相对时间坐标系。

通过解析数据目录命名特征 (“铺装”/“非铺装” 关键词) 自动选择预测模型。非铺装路面采用最小二乘法拟合, 铺装路面启动蒙特卡洛优化

应用模型生成未来 10 年磨损深度演变曲线, 输出带置信区间的预测报告及可视化图表。

本方法通过严格的理论推导与工程约束结合, 破解了传统模型在复杂工况下的适应性难题, 在保持计算效率的同时, 将长期预测精度提升至毫米级, 为预防性养护提供了可靠量化依据。

5. 软件数据流程

从无人机定位飞行与图像采集到路面缺陷识别生成绕飞区坐标; 从路径规划控制无人机循迹飞行到多传感器同步采集公路磨损深度数据; 从数据分析与区域磨损深度重组到区域生长算法划分不同磨损情况路段; 从双模型预测到预测路面磨损趋势。

四、系统功能验证

(一) 路面缺陷精确检测

如图 6 所示, 图像识别训练过程及测试正确率高达 100%。

```

train num: 35390 val num: 4610
{'Negative': 0, 'Positive': 1}
lr: 0.0001
35390 1106
Train Epoch: 1 [1600/35390 (5%)] Loss: 0.234289
Train Epoch: 1 [3200/35390 (9%)] Loss: 0.159111
Train Epoch: 1 [4800/35390 (14%)] Loss: 0.040075
Train Epoch: 1 [6400/35390 (18%)] Loss: 0.079507
Train Epoch: 1 [8000/35390 (23%)] Loss: 0.128617
Train Epoch: 1 [9600/35390 (27%)] Loss: 0.022644
Train Epoch: 1 [11200/35390 (32%)] Loss: 0.017634
Train Epoch: 1 [12800/35390 (36%)] Loss: 0.199377
Train Epoch: 1 [14400/35390 (41%)] Loss: 0.138423
Train Epoch: 1 [16000/35390 (45%)] Loss: 0.011004
Train Epoch: 1 [17600/35390 (50%)] Loss: 0.079852
Train Epoch: 1 [19200/35390 (54%)] Loss: 0.065389
Train Epoch: 1 [20800/35390 (59%)] Loss: 0.127542
Train Epoch: 1 [22400/35390 (63%)] Loss: 0.186894
Train Epoch: 1 [24000/35390 (68%)] Loss: 0.068822
Train Epoch: 1 [25600/35390 (72%)] Loss: 0.098998
Train Epoch: 1 [27200/35390 (77%)] Loss: 0.093992
Train Epoch: 1 [28800/35390 (81%)] Loss: 0.080485
Train Epoch: 1 [30400/35390 (86%)] Loss: 0.060681
Train Epoch: 1 [32000/35390 (90%)] Loss: 0.196152
Train Epoch: 1 [33600/35390 (95%)] Loss: 0.157594
Train Epoch: 1 [35200/35390 (99%)] Loss: 0.037217
epoch:1,loss:0.14240562507527363
4610 145

Val set: Average loss: 0.0042, Accuracy: 4606/4610 (100%)

```

图 6 图像识别训练过程

(二) 区域磨损深度重构

绕飞区精准定位统计表、区域各点磨损深度重组统计表如图 7 和图 8 所示。

文件	编辑	查看
h.txt	no_fly	
3 4 6 8		
6 8 13 13		
2 4 21 22		
8 10 46 46		
5 5 31 33		
3 3 89 91		
6 8 16 17		
4 7 61 61		
2 2 73 75		
4 6 26 27		
1 3 41 42		
5 6 96 97		
9 10 11 12		
3 3 51 53		
2 5 66 66		
6 7 81 82		
7 8 36 37		
3 4 23 24		
1 1 76 78		
4 5 91 92		
5 6 4 5		
8 9 19 20		
2 3 56 57		
6 7 29 30		

图 7 绕飞区精准定位统计表

文件	编辑	查看
y_zones	depth	
1.76 1.60 1.50 1.45 1.64 1.56 1.43 1.41 1.30 1.52		
1.68 1.62 1.63 1.49 1.70 1.53 1.53 1.54 1.60 1.75		
1.64 1.49 1.50 1.57 1.91 2.04 1.61 1.61 1.60 1.54		
1.76 1.59 1.46 1.87 3.53 4.08 1.84 1.60 1.39 1.53		
1.55 1.98 2.11 2.46 4.05 4.93 1.96 1.51 1.47 1.55		
1.96 4.53 5.28 4.66 2.11 2.04 1.57 1.53 1.58 1.59		
2.29 5.10 4.07 3.73 1.79 1.60 1.65 1.55 1.48 1.66		
1.72 2.42 4.94 3.73 1.79 1.63 1.72 1.66 1.61 1.48		
1.43 1.56 2.01 1.93 1.53 1.64 1.68 1.66 1.62 1.53		
1.37 1.49 1.62 1.74 1.59 1.69 1.72 1.52 1.89 2.22		
1.57 1.52 1.58 1.59 1.51 1.57 1.58 1.94 5.28 5.34		
1.57 1.45 1.50 1.41 1.36 1.67 2.19 2.57 4.66 3.59		
1.40 1.60 1.62 1.50 1.75 3.52 5.22 4.66 2.40 2.10		
1.68 1.56 1.48 1.44 1.53 1.75 2.20 2.22 1.75 1.51		
1.56 1.56 1.57 1.54 1.52 1.97 2.06 2.20 1.51 1.58		
1.61 1.63 1.50 1.65 1.98 4.36 3.82 4.64 1.94 1.72		
1.34 1.55 1.62 1.55 1.96 5.05 4.48 3.50 1.83 1.68		
1.34 1.49 1.57 1.54 1.62 2.12 1.85 2.33 2.13 1.81		
1.72 1.68 1.57 1.55 1.45 1.58 1.94 4.74 4.39 2.06		
1.76 2.09 2.03 1.87 1.52 1.55 2.18 5.26 3.65 1.99		
2.12 4.89 5.44 3.85 2.05 1.67 1.79 2.10 1.91 1.67		
1.91 3.44 5.15 3.78 1.90 1.36 1.44 1.70 1.61 1.51		
1.65 2.04 3.41 4.88 1.84 1.31 1.53 1.85 1.69 1.53		
1.71 2.11 5.11 4.93 2.02 1.59 1.54 1.62 1.64 1.58		
1.40 1.48 2.01 2.42 1.97 1.90 1.61 1.45 1.71 1.61		

图 8 区域各点磨损深度重组统计表

（三）区域生长深度划分与统计

通过区域生长算法划分出磨损情况相似的采样点为一个区域，划分前后的磨损情况热图如图 9所示。




图 9 划分前后的磨损情况

划分后区域磨损深度详细信息统计表如图 10所示。

区域ID	平均深度	深度标准差	最小深度	最大深度	区域面积
1	1.647242	0.207621	1.22	2.74	794
2	4.461429	0.573745	3.53	5.28	7
3	5.032	0.306098	4.66	5.34	5
4	3.52	0	3.52	3.52	1
5	4.4675	0.447179	3.82	5.05	4
6	4.796667	0.357429	4.39	5.26	3
7	5.165	0.275	4.89	5.44	2
8	3.85	0	3.85	3.85	1
9	3.44	0	3.44	3.44	1
10	5.11	0	5.11	5.11	1
11	4.3025	0.443755	3.61	4.84	4
12	4.461429	0.288317	4.01	4.99	7
13	3.72	0.16	3.56	3.88	2
14	3.56	0	3.56	3.56	1
15	5.245	0.225	5.02	5.47	2
16	4.6325	0.495902	3.94	5.31	4
17	3.74	0	3.74	3.74	1
18	5.225	0.125	5.1	5.35	2
19	4.11	0.294052	3.79	4.5	3
20	3.793333	0.241155	3.49	4.08	3
21	4.826667	0.179134	4.58	5	3
22	3.993333	0.493784	3.54	4.68	3
23	5.39	0	5.39	5.39	1
24	5.16	0.07	5.09	5.23	2
25	3.79	0	3.79	3.79	1
26	4.095	0.125	3.97	4.22	2

图 10 划分后区域磨损深度详细信息统计表

（四）精准磨损深度预测

通过建立的磨损深度预测数学模型，代入若干个年份的数据，可得到此后每年的精准磨损深度预测值。图 11 展示了其中两个区域的磨损深度预测曲线，具体数据如图 12 所示。




图 11 区域磨损深度预测曲线




图 12 区域磨损深度预测数据

五、项目优势

（一）算法优势

1. 路面缺陷精确识别

基于轻量化 ResNet-18 架构，由项目中的 ‘DefectDetector’ 类实现，融合迁移学习与动态剪枝技术，在 Crazyflie 2.1 机载 Jetson AGX Xavier 平台实现：支持 6 类路面缺陷

分类管理，由模型输出的‘*defecttype*’参数进行验证。采用亚像素级数据增强策略，代码中‘*transform*’包含随机裁剪/旋转，提升复杂光照场景鲁棒性。

2. 改进 A* 算法高效路径规划

创新性融合威胁权重因子,实现缺陷密度自适应的路径避让。通过优化搜索机制,使路径长度比传统 A* 算法缩短,转角次数减少,显著降低了无人机的能耗。

（二）模型优势

1. 多模态预测架构

针对铺装路面磨损预测采用蒙特卡洛积分模型：通过 1000 次随机参数搜索求解材料-荷载-环境耦合方程，实验证明 10 年期预测误差小于 0.7mm。

非铺装路面指数-线性混合模型：动态计算初始参数，提升对砂石和的预测精度。

2. 动态鲁棒性增强

基于深度数据分布动态计算生长阈值，并支持大理石/混凝土/砖等 6 类材质的无缝切换。

（三）系统优势

1. 全链条自动化

无人化作业流程由项目的 *main* 函数完整实现。由 *executepath* 实现自主起飞到路径跟随。由 *validatedepthdata* 验证机制实现异常自处理，并通过 *saveresults* 输出 Excel 和 PNG 文件，自动生成报告。

2. 工程可扩展性

硬件接口标准化，且支持即插即用扩展热像仪/气体传感器等外设。通信协议兼容 MAVLink/ROS。软件架构具有模块化的特点，代码严格分离数据采集/处理/存储模块。

六、应用前景

（一）商业价值

公路基础设施的规模化发展对养护效率与安全性提出了更高要求，然而传统人工巡检模式长期面临三大瓶颈：

经济性不足，依赖专业检测车辆与多人协同作业，设备折旧与人力成本居高不下。

风险不可控，高危路段作业事故多发，且恶劣环境下检测精度波动显著。

决策滞后性，从缺陷发现到维护实施周期长，导致小病害发展为结构性损伤。

本系统通过无人机智能巡检技术重构商业模式，实现多维价值突破：

借助全流程自动化操作，让无人机可以根据检测路线自己规划飞行路径，同时还能在飞行过程中自动完成深度数据采集工作。使用此方案可以省去传统的人工登高作业、道路封闭等额外产生的费用，大大降低了单位面积的检测成本。

采用微型无人机加上边缘计算模块的轻便设计，通过 InspectionDrone（检测专用无人机）的先进架构，使得在设备投入上相比传统的检测车辆减少 90% 以上的成本。

（二）产品优势

表 3 传统方案与本系统创新点对比

对比维度	传统方案缺陷	本系统创新点
检测精度	人工经验判断,夜间/不良天气漏检率高	基于 ResNet-18 的实时视觉检测,支持多种光照条件下稳定输出,解决传统主观误判与环境敏感性的痛点
覆盖效率	人工巡检需频繁转移设备与人员,单日覆盖范围受限	无人机自主飞行与自动充电,可以实现 24 小时连续作业,突破人力资源与地理约束
预测能力	经验公式难以量化材料老化与行人与车辆荷载耦合效应	蒙特卡洛随机参数搜索与物理驱动模型融合可以有效破解存在的难题,可以实现长周期退化演算,做到精准建模
部署成本	大型检测设备需要专用运输车辆与操作团队	微型无人机系统可装入标准的工具箱,单人即可完成部署操作,开启轻量化、低门槛运维新模式

本系统的商业化路径已通过典型场景验证：例如在日常巡查工作中，系统生成的路线点位文件能够根据实际情况灵活调整检测的密集度；在特殊路段的检测中，磨损预测模型表现出很强的匹配能力。这些实践成果证明，该系统成功打破了传统养护方案在成本控制、作业效率和安全保障方面难以兼顾的困境，为道路维护的智能化提供了重要的技术保障。

（三）未来展望

代码层面，基于代码中 Jetson AGX Xavier 的算力冗余（当前利用率约 68%），部署联邦学习框架实现多机模型协同更新，增强边缘计算。开发模型量化工具，适配 Defect-Detector 类，压缩模型体积。扩展代码中 ‘radio : //’ 协议，支持 Swarm 模式下的任务分配（当前代码支持单机全功能）。基于现有路径规划算法开发冲突检测模块，确保机群安全间距。

能效方面，可进一步利用飞行过程中返回的姿态数据优化飞行姿态，降低能耗。同时开发光伏充电模块，适配 Crazyfly 2.1 电源接口，延长续航时间。

结论

我们团队研发的这套基于无人机的一体化智能公路维护系统，从图像采集到做出维护决策，整个流程都能自主完成，形成了一个完整的闭环。

以前，我国公路养护领域一直存在两个大问题，一是“传统检测碎片化”，即检测工作零零散散，不够集中；二是“人工预测经验化”，主要靠人的经验来判断公路状况，很难做出科学判断。而我们这套系统的出现在一定程度上解决了这两个难题。通过构建无人机检测系统与新创的算法体系，破解了路面材料的时变特性与交通环境复杂变化耦合的建模难题。系统中建立了一个结合物理原理和数据驱动的退化预测模型，还开发了能自动识别多种路面材质的算法，使之在各种复杂场景下也能够完美适用。

我们的这套系统可以给公路养护数字化转型提供一个可以借鉴的技术方法，能让传统的公路维护，从“坏了才修”变成“提前预测、提前维护”，把存在的安全隐患提前消除，避免重大事故发生。我们的这套系统是一个开放、可扩展的技术生态系统，有完整的技术体系，包括检测标准、算法模型和硬件平台，利用模块化设计，能满足桥梁公路、隧道公路等多种公路基础设施的检测需求，不仅应用广泛也很容易推广。

我们研发的这套系统可以说在我国交通基础设施智能养护领域是个不小的突破。它采用“轻量化无人机硬件 + 开创性智能算法 + 科学的系统集成”的创新模式，不仅能大大提高公路运行维护的效率和安全性，还为新型公路基础设施建设提供了有力的技术支持。未来，我们还会把无人机 5G 多机协同、数字孪生等新技术更深入地融合进来，不断完善和发展智能公路维护系统，为国家基础设施的建设和养护贡献出更多力量。

参考文献

- [1] 纪文君. 公路桥梁管理中的智能监测技术应用 [J]. 运输经理世界, 2024, (17): 93-95.
- [2] 郭锦涛, 王涛, 胡永恒. 高速公路智能巡检养护管理系统的开发与应用 [C] 中国高科技产业化研究会智能信息处理产业化分会. 第十八届全国信号和智能信息处理与应用学术会议论文集. 国能龙源环保有限公司特许运维事业部; 国能龙源环保有限公司宿州分公司;,2024:643-648.DOI:10.26914/c.cnkihy.2024.050454.
- [3]Jiale L ,Guohui Y ,Xuefei W , et al.*Automated decision making in highway pavement preventive maintenance based on deep learning*[J].Automation in Construction,2022,135
- [4]Karballaezadeh N ,Zaremotekhas F ,Shamshirband S , et al.*Intelligent Road Inspection with Advanced Machine Learning; Hybrid Prediction Models for Smart Mobility and Transportation Maintenance Systems*[J].Energies,2020,13(7):
- [5]Silva, L. A., Leithardt, V. R. Q., Batista, V. F. L., Gonzalez, G. V., & Santana, J. F. D. P. (2023). *Automated road damage detection using UAV images and deep learning techniques*. IEEE Access, 11, 62918-62931.
- [6] Archard J F. *Contact and rubbing of flat surfaces*[J]. Journal of applied physics, 1953, 24(8): 981-988.
- [7] Kohout J. *Modified Arrhenius equation in materials science, chemistry and biology*[J]. Molecules, 2021, 26(23): 7162.
- [8] Kato K. *Wear in relation to friction—a review*[J]. wear, 2000, 241(2): 151-157.
- [9] Metropolis N, Ulam S. *The monte carlo method*[J]. Journal of the American statistical association, 1949, 44(247): 335-341.